

Studi Ablasi pada Preprocessing, Seleksi Fitur, PCA, dan Regularisasi untuk Prediksi Nilai Ujian Mahasiswa

Mar'iy Romizzidi Amly
Magister Kecerdasan Artifisial
Departemen Ilmu Komputer dan Elektronika
Universitas Gadjah Mada, Yogyakarta, Indonesia
NIM: 26/589558/PPA/07365

https://colab.research.google.com/drive/1HpLiB0MFL0z_-bOXbQFI5nZ78tv28tum?usp=sharing
<https://github.com/romizzidiamly/ablation-study-linear-regression>

Abstract—Laporan ini membahas studi ablasi pada pipeline regresi linear untuk memprediksi nilai ujian mahasiswa. Fokus eksperimen bukan hanya mencari konfigurasi dengan nilai galat paling kecil, tetapi melihat seberapa besar perubahan setiap komponen pipeline memengaruhi hasil ketika komponen lain dibuat tetap. Dataset terdiri atas 1.000 data mahasiswa dengan 16 kolom, kemudian dibagi menjadi data latih dan data uji dengan rasio 80:20. Evaluasi pada data latih dilakukan menggunakan 10-fold cross-validation dengan pembagian fold yang sama untuk seluruh konfigurasi. Sebanyak 49 konfigurasi atau 490 hasil fold dievaluasi. Eksperimen menunjukkan bahwa standardisasi tidak mengubah prediksi ordinary least squares pada dataset ini. Penambahan variabel kategorikal justru sedikit meningkatkan RMSE. Perubahan yang paling menarik muncul pada seleksi fitur: konfigurasi A1 dengan tujuh fitur menghasilkan CV RMSE terendah sebesar 5.4140 ± 0.5716 dan pada hold-out test memperoleh RMSE 5.0745 serta R^2 sebesar 0.8996. PCA memberikan kompresi dimensi yang cukup baik tetapi tidak mengungguli seleksi fitur, sedangkan regularisasi tidak memberikan peningkatan akurasi yang berarti karena baseline sejak awal tidak menunjukkan indikasi overfitting yang kuat; manfaatnya lebih terlihat pada pengurangan jumlah koefisien aktif. Hasil ini menunjukkan bahwa studi ablasi membantu menjelaskan kontribusi setiap komponen pipeline secara lebih masuk akal dibandingkan hanya melaporkan skor model akhir.

Index Terms—studi ablasi, regresi linear, seleksi fitur, PCA, regularisasi, cross-validation, prediksi performa mahasiswa

I. PENDAHULUAN

Ketika sebuah model machine learning menghasilkan nilai RMSE yang baik, mudah untuk langsung menyimpulkan bahwa seluruh pipeline yang digunakan sudah tepat. Masalahnya, satu angka tersebut tidak menjelaskan bagian mana dari pipeline yang benar-benar memberi kontribusi. Pada data tabular, perubahan yang terlihat sederhana seperti standardisasi, encoding variabel kategorikal, seleksi fitur, reduksi dimensi, atau regularisasi dapat mengubah representasi data dan pada akhirnya mengubah performa model.

Studi ablasi digunakan untuk menjawab pertanyaan tersebut secara lebih terkontrol. Prinsipnya sederhana: satu komponen diubah, sedangkan kondisi lain dibuat sama. Dengan cara ini, perbedaan performa dapat dikaitkan dengan intervensi yang sedang diuji, bukan dengan perubahan konfigurasi yang terjadi secara bersamaan. Pendekatan evaluasi yang membandingkan beberapa konfigurasi secara konsisten juga sejalan dengan prinsip model selection berbasis validasi silang, yang membantu memperkirakan kemampuan generalisasi tanpa menjadikan satu pembagian data sebagai satu-satunya dasar keputusan [1].

Pada tugas ini, `exam_score` digunakan sebagai target regresi. Eksperimen dibangun dalam beberapa tahap kontrol, yaitu B0 sampai B3, kemudian dilanjutkan dengan tiga kelompok ablasi utama. A1 menguji seleksi fitur menggunakan SelectKBest, A2 menguji PCA berdasarkan target explained variance, sedangkan A3 menguji regularisasi Ridge, Lasso, dan ElasticNet. Seleksi fitur digunakan untuk mempertahankan subset prediktor yang paling informatif dengan tujuan antara lain meningkatkan efisiensi dan interpretabilitas model [2]. PCA digunakan sebagai pendekatan reduksi dimensi yang membentuk kombinasi linear baru dengan mempertahankan sebanyak mungkin variasi data [3]. Semua konfigurasi menggunakan train-test split dan pembagian 10-fold yang sama. Dengan rancangan tersebut, pertanyaan utama penelitian bukan sekadar “konfigurasi mana yang mempunyai test RMSE paling kecil?”, tetapi “perubahan apa yang benar-benar memberikan pengaruh terhadap model?”.

II. URUTAN STUDI ABLASI

Eksperimen disusun sebagai urutan intervensi yang terkontrol. Agar pembacaan hasil tidak dimulai dari model terbaik, alur penelitian ditetapkan terlebih dahulu: baseline dibangun, komponen preprocessing ditambahkan satu per satu, kemudian dilakukan tiga jenis ablasi yang lebih spesifik. Dengan demikian, setiap tahap mempunyai fungsi yang berbeda dan hasil antar tahap dapat dibandingkan secara langsung.




Fig. 1: Urutan eksperimen ablasi. B0–B3 berfungsi sebagai tahap kontrol, sedangkan A1–A3 menguji intervensi pada representasi fitur dan estimator.

TABLE I: Kelompok eksperimen dan jumlah konfigurasi.

Blok	N	Intervensi utama
B0	1	Baseline numerik
B1	1	Scaling + imputasi numerik
B2	1	Penambahan prediktor kategorikal
B3	1	Ridge ($\alpha = 1$)
A1	6	Seleksi fitur SelectKBest
A2	4	PCA berdasarkan explained variance
A3	35	Ridge/Lasso/ElasticNet
Total	49	10-fold CV = 490 fold

B0 merupakan baseline dengan delapan prediktor numerik. B1 menambahkan median imputation dan StandardScaler. B2 menambahkan enam prediktor kategorikal melalui one-hot encoding. B3 mengganti estimator OLS pada B2 dengan Ridge dengan $\alpha = 1$.

A1 menguji SelectKBest dengan $k \in \{4, 7, 9, 12, 15\}$ serta satu konfigurasi seluruh fitur. Secara konseptual, feature selection dapat mengurangi dimensi sekaligus mempertahankan prediktor yang lebih relevan terhadap tujuan prediksi [2]. A2 mengganti seleksi fitur dengan PCA menggunakan target explained variance 80%, 90%, 95%, dan 99%. PCA menghasilkan komponen baru yang saling tidak berkorelasi dan diurutkan berdasarkan variasi yang dijelaskan, sehingga cocok digunakan untuk menguji trade-off antara reduksi dimensi dan informasi yang dipertahankan [3]. A3 menguji tujuh nilai α untuk Ridge, tujuh nilai untuk Lasso, serta 21 kombinasi ElasticNet. Secara keseluruhan terdapat 49 konfigurasi dan 490 hasil fold.

III. DATASET DAN DETAIL IMPLEMENTASI

A. Dataset

Eksperimen menggunakan berkas `student_habits_performance.csv`. Dataset berisi 1.000 observasi dan 16 kolom. Kolom `student_id` hanya berfungsi sebagai identifikasi sehingga tidak digunakan sebagai prediktor. Target yang diprediksi adalah `exam_score`. Dengan demikian, terdapat 14 kandidat prediktor yang terdiri atas delapan variabel numerik dan enam variabel kategorikal.

Rata-rata target `exam_score` adalah 69.6015 dengan simpangan baku 16.8886. Nilai terendah dan tertinggi masing-masing adalah 18.4 dan 100.0. Missing value hanya ditemukan pada `parental_education_level`, yaitu sebanyak

TABLE II: Variabel yang digunakan dalam eksperimen.

Variabel	Tipe	Peran
age	Numerik	Prediktor
study_hours_per_day	Numerik	Prediktor
social_media_hours	Numerik	Prediktor
netflix_hours	Numerik	Prediktor
attendance_percentage	Numerik	Prediktor
sleep_hours	Numerik	Prediktor
exercise_frequency	Numerik	Prediktor
mental_health_rating	Numerik	Prediktor
gender	Kategorikal	Prediktor
part_time_job	Kategorikal	Prediktor
diet_quality	Kategorikal	Prediktor
parental_education_level	Kategorikal	Prediktor
internet_quality	Kategorikal	Prediktor
extracurricular_participation	Kategorikal	Prediktor
exam_score	Numerik	Target

91 data. Variabel kategorikal memiliki dua sampai tiga kategori. Kondisi ini penting karena jumlah kolom pada matriks fitur akan bertambah setelah one-hot encoding.

B. Pembagian Data dan Cross-Validation

Data dibagi menggunakan train–test split sebesar 80:20 dengan `random_state=42`. Hasilnya adalah 800 observasi untuk training dan 200 observasi untuk test. Rata-rata `exam_score` pada data training adalah 69.827, sedangkan pada data test adalah 68.698.

Pada data training digunakan shuffled 10-fold KFold dengan `random_state=42`. Pembagian fold dibuat sama untuk semua konfigurasi. Penggunaan 10-fold cross-validation merupakan pilihan yang umum dalam evaluasi dan model selection, dengan studi klasik Kohavi menunjukkan kegunaan 10-fold cross-validation untuk estimasi performa dan pemilihan model [1]. Oleh karena itu, perbedaan CV RMSE antarkonfigurasi dapat dibaca sebagai hasil perubahan pipeline, bukan akibat penggunaan pembagian data yang berbeda. Data test disimpan sebagai hold-out dan tidak digunakan untuk memilih konfigurasi terbaik.

C. Preprocessing dan Pencegahan Data Leakage

Variabel numerik menggunakan median imputation, sedangkan variabel kategorikal menggunakan most-frequent imputation. Variabel kategorikal kemudian diubah menggunakan one-hot encoding dengan `drop='first'` dan `handle_unknown='ignore'`. Setelah preprocessing, representasi penuh menghasilkan 18 fitur.

Pemakaian `drop='first'` juga penting secara matematis. Jika semua level kategori dipertahankan sementara model mempunyai intercept, kolom dummy dapat membentuk ketergantungan linear sempurna. Audit pada hasil eksperimen menunjukkan bahwa encoding penuh menghasilkan 24 kolom tetapi rank hanya 19 dan condition number sekitar 1.34×10^{16} . Setelah kategori pertama dihapus, representasi menjadi 18 kolom dengan rank 18 dan condition number sekitar 5.65. Menariknya, test RMSE OLS tetap sama, yaitu 5.151, sehingga perbaikan tersebut terutama menyangkut identifiabilitas koefisien, bukan perubahan prediksi pada eksperimen ini.

Seluruh transformasi yang dipelajari dari data ditempatkan di dalam pipeline scikit-learn. Dengan demikian, imputasi, scaling, one-hot encoding, SelectKBest, dan PCA di-fit ulang di dalam masing-masing fold. Cara ini mencegah informasi dari validation fold masuk ke proses fitting pada training fold.

D. Metrik Evaluasi

Tiga metrik utama digunakan dalam laporan ini:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (1)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (2)$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}. \quad (3)$$

RMSE dan MAE yang lebih kecil menunjukkan prediksi yang lebih baik, sedangkan R^2 yang lebih besar lebih baik. Selain metrik tersebut, hasil eksperimen juga menyimpan Δ train/test gap, Δ CV/test gap, jumlah koefisien non-zero, dan waktu training.

IV. HASIL DAN ANALISIS BERDASARKAN URUTAN ABLASI

Bagian ini mengikuti urutan eksperimen yang sudah ditetapkan pada awal studi. Setiap tahap dibahas secara terpisah agar perubahan metrik dapat dikaitkan langsung dengan intervensi yang dilakukan. Untuk seluruh tahap, kriteria pemilihan konfigurasi terbaik adalah mean CV RMSE terendah. Nilai test hanya digunakan setelah konfigurasi dipilih dan tidak dipakai untuk menentukan pemenang.

A. Ablasi B0: Baseline

B0 digunakan sebagai titik acuan seluruh perbandingan. Model yang dipakai adalah ordinary least squares (OLS) dengan delapan prediktor numerik tanpa scaling dan tanpa penambahan variabel kategorikal. Hasilnya menghasilkan CV RMSE sebesar 5.4221 ± 0.5827 , test RMSE 5.0913, test MAE 4.1302, dan test R^2 0.8989. Karena seluruh perubahan berikutnya dibandingkan dengan B0, nilai-nilai ini menjadi referensi utama untuk membaca perubahan absolut (Δ).

B. Ablasi B1: Imputasi dan Standardisasi

B1 menambahkan median imputation dan StandardScaler pada delapan prediktor numerik. Secara numerik, tidak terjadi perubahan sama sekali pada prediksi OLS. CV RMSE tetap 5.4221 ± 0.5827 dan seluruh metrik test tetap sama dengan B0. Audit prediksi juga menunjukkan perbedaan absolut maksimum prediksi sebesar nol. Temuan ini masuk akal untuk OLS dengan intercept karena perubahan skala linear tidak mengubah ruang prediksi model.

Kesimpulan tahap ini bukan bahwa scaling tidak berguna secara umum, melainkan bahwa scaling tidak memberi keuntungan prediktif pada estimator OLS yang digunakan

dalam eksperimen ini. Hasil B1 menjadi penting karena kemudian StandardScaler dipertahankan pada B2 dan A1–A3 ketika komponen yang diuji membutuhkan representasi fitur yang konsisten.

C. Ablasi B2: Penambahan Variabel Kategorikal

B2 menambahkan enam prediktor kategorikal dan menghasilkan 18 fitur setelah one-hot encoding dengan drop-first. Perubahan ini justru memperburuk performa dibandingkan B0: CV RMSE meningkat menjadi 5.4816 ± 0.5893 dan test RMSE menjadi 5.1510. Test R^2 turun dari 0.8989 menjadi 0.8965.

Hasil tersebut menunjukkan bahwa penambahan informasi tidak otomatis meningkatkan kemampuan prediksi. Pada data ini, variabel kategorikal menambah dimensi tanpa memberikan sinyal prediktif yang cukup kuat untuk mengimbangi kompleksitas tambahan.

D. Ablasi B3: Penggantian OLS dengan Ridge

B3 mempertahankan representasi B2, tetapi mengganti OLS dengan Ridge $\alpha = 1$. Ridge menambahkan penalti kuadrat terhadap koefisien dan secara klasik diperkenalkan untuk menghadapi masalah regresi dengan prediktor yang tidak ortogonal [4]. Perubahannya sangat kecil: CV RMSE menjadi 5.4803 ± 0.5881 dan test RMSE 5.1515. Dibandingkan B2, regularisasi ringan ini belum memberikan keuntungan prediktif.

Dengan demikian, B0–B3 menunjukkan baseline yang relatif stabil sampai fitur kategorikal ditambahkan. B3 kemudian menjadi tahap kontrol untuk menguji apakah regularisasi yang lebih sistematis pada A3 dapat menghasilkan trade-off yang lebih baik.




Fig. 2: Perbandingan tahap kontrol B0–B3. Standardisasi tidak mengubah OLS, sedangkan penambahan fitur kategorikal sedikit meningkatkan galat.

E. Ablasi A1: Feature Selection dengan SelectKBest

A1 menguji seberapa banyak fitur yang sebenarnya dibutuhkan setelah B2. Enam konfigurasi dibandingkan: $k = 4, 7, 9, 12, 15$ dan seluruh 18 fitur sebagai kontrol integritas. Hasil lengkap ditunjukkan pada Tabel VII.

Hasil terbaik A1 adalah $k = 7$ dengan CV RMSE 5.4140 ± 0.5716 . Nilai ini merupakan yang terendah dari seluruh 49 konfigurasi. Keuntungan tersebut bukan berupa lonjakan akurasi, tetapi berupa kombinasi antara performa sedikit lebih baik daripada B0 sekaligus mengurangi 61.1% fitur hasil encoding.

TABLE III: Hasil B0 sebagai baseline.

Konfig.	ID	Model	Scaling	N fitur	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
B0	B0	LinearRegression	tanpa scaling	8	5.4221 ± 0.5827	5.0913	4.1302	0.8989

TABLE IV: Perbandingan B0 dan B1.

Konfig.	Scaler	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
B0	tanpa scaling	5.4221 ± 0.5827	5.0913	4.1302	0.8989
B1	StandardScaler	5.4221 ± 0.5827	5.0913	4.1302	0.8989

TABLE V: Hasil B2 dibandingkan baseline.

Konfig.	Fitur akhir	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
B2	18	5.4816 ± 0.5893	5.1510	4.1923	0.8965

TABLE VI: Hasil B3.

Konfig.	Estimator	N fitur	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
B3	Ridge ($\alpha = 1$)	18	5.4803 ± 0.5881	5.1515	4.1920	0.8965

TABLE VII: Hasil lengkap A1: SelectKBest.

Konfig.	k	N akhir	Reduksi (%)	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
k4	4	4	77.8	6.8459 ± 0.5214	6.9156	5.6822	0.8135
k7	7	7	61.1	5.4140 ± 0.5716	5.0745	4.1139	0.8996
k9	9	9	50.0	5.4261 ± 0.5762	5.0826	4.1151	0.8993
k12	12	12	33.3	5.4376 ± 0.5993	5.0759	4.1122	0.8995
k15	15	15	16.7	5.4824 ± 0.5871	5.1351	4.1740	0.8972
kall	semua	18	0.0	5.4816 ± 0.5893	5.1510	4.1923	0.8965

Ketika hanya empat fitur dipertahankan, CV RMSE meningkat tajam menjadi 6.8459 dan test RMSE 6.9156. Ini menunjukkan bahwa seleksi terlalu agresif menyebabkan kehilangan informasi. Sebaliknya, $k = 9$ dan $k = 12$ tetap sangat dekat dengan hasil terbaik. Fitur yang dipertahankan pada A1- $k = 7$ adalah `study_hours_per_day`, `social_media_hours`, `netflix_hours`, `attendance_percentage`, `sleep_hours`, `exercise_frequency`, dan `mental_health_rating`. Seluruhnya merupakan fitur numerik.

Berkurangnya fitur pada A1 sebaiknya tidak ditafsirkan sebagai bukti bahwa fitur yang tereliminasi “tidak penting” secara kausal. SelectKBest menilai kekuatan hubungan statistik fitur terhadap target berdasarkan skor seleksi yang digunakan pada pipeline. Karena tujuh fitur terpilih seluruhnya numerik, hasil ini mengindikasikan bahwa pada dataset ini fitur-fitur numerik tersebut mempunyai sinyal marginal yang lebih kuat atau lebih konsisten terhadap `exam_score` dibandingkan representasi dummy dari variabel kategorikal. Variabel kategorikal juga terpecah menjadi beberapa kolom one-hot, sehingga kontribusi masing-masing level dinilai secara terpisah. Selain itu, sebagian informasi antarfitur dapat bersifat tumpang tindih, sehingga tidak semua fitur perlu dipertahankan untuk memperoleh performa yang hampir sama. Namun, mekanisme tersebut merupakan interpretasi statistik dari hasil ablasi, bukan bukti hubungan sebab-akibat.




Fig. 3: Hasil A1 berdasarkan jumlah fitur. Titik $k = 7$ memberikan CV RMSE terendah, sedangkan $k = 4$ menunjukkan indikasi underfitting akibat reduksi yang terlalu agresif.

F. Ablasi A2: Principal Component Analysis

A2 menguji apakah dimensi dapat dikurangi melalui PCA tanpa memilih fitur asli secara langsung. Target explained variance yang diuji adalah 80%, 90%, 95%, dan 99%. Hasil lengkap ditampilkan pada Tabel VIII.


A2 terbaik berada pada target explained variance 80%, dengan delapan komponen dan explained variance aktual 0.8157. CV RMSE mencapai 5.4359 ± 0.5984 dan test RMSE 5.0971. Nilai tersebut masih sangat dekat dengan baseline, tetapi tetap sedikit lebih buruk daripada A1- $k = 7$. Ketika semakin banyak komponen dipertahankan, performa bergerak kembali mendekati B2. Pada target 99%, CV RMSE menjadi 5.4711.

G. Ablasi A3: Regularisasi Ridge, Lasso, dan ElasticNet

A3 merupakan kelompok terbesar dengan 35 konfigurasi. Ridge dan Lasso diuji pada tujuh nilai alpha, sedan-

TABLE VIII: Hasil lengkap A2: PCA.

Target EV	Komponen	EV aktual	Reduksi (%)	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
80%	8	0.8157	55.6	5.4359 ± 0.5984	5.0971	4.1184	0.8987
90%	11	0.9018	38.9	5.4442 ± 0.5810	5.1008	4.1369	0.8985
95%	14	0.9657	22.2	5.4491 ± 0.5719	5.1150	4.1608	0.8980
99%	17	0.9960	5.6	5.4711 ± 0.5848	5.1539	4.1923	0.8964

Fig. 4: Hasil A2 berdasarkan target explained variance PCA. Kompresi 80% memberikan hasil terbaik dalam keluarga PCA, tetapi masih kalah dari A1- $k = 7$.

gkan ElasticNet diuji pada tujuh alpha dan tiga nilai l_1 ratio. Lasso memperkenalkan penalti L_1 yang dapat menghasilkan koefisien tepat nol sehingga mendukung seleksi variabel [5], sedangkan Elastic Net menggabungkan penalti L_1 dan L_2 serta dapat mempertahankan kelompok prediktor yang berkorelasi [6]. Karena jumlah konfigurasi cukup banyak, seluruh hasil ditampilkan agar trade-off antara akurasi dan sparsity dapat terlihat, bukan hanya konfigurasi terbaik.

Dari keluarga A3, Lasso dengan $\alpha = 0.1$ menjadi konfigurasi terbaik berdasarkan CV RMSE, yaitu 5.4311 ± 0.5519 . Model ini mempunyai sembilan koefisien non-zero dari 18 fitur, tetapi test RMSE 5.1096 dan $R^2 = 0.8982$ masih sedikit lebih buruk daripada baseline B0. Pola ini konsisten dengan hasil B3: Ridge $\alpha = 1$ juga tidak memberikan peningkatan prediktif yang berarti. Baseline B0 sendiri tidak menunjukkan indikasi overfitting yang kuat: RMSE training sebesar 5.3754 justru sedikit lebih tinggi daripada RMSE test sebesar 5.0913, sedangkan R^2 training 0.9010 sangat dekat dengan R^2 test 0.8989. Karena tidak ada kompleksitas berlebih yang jelas untuk dikendalikan, regularisasi tidak mempunyai masalah overfitting yang kuat untuk diperbaiki dan manfaatnya terhadap akurasi menjadi terbatas. Dengan demikian, A3 lebih tepat dibaca sebagai studi sparsity dan pengurangan kompleksitas koefisien. Interpretasi ini sesuai dengan karakteristik Lasso dan Elastic Net sebagai metode regularisasi yang sekaligus dapat melakukan seleksi variabel [5], [6]. Ketika α diperbesar terlalu jauh, terutama pada Lasso dan ElasticNet, performa justru memburuk karena penalti mulai menghapus terlalu banyak informasi dan menyebabkan underfitting.

ElasticNet menunjukkan pola serupa. Kombinasi moderat, terutama $\alpha = 0.1$ dengan $l_1 = 0.9$, menghasilkan sembilan koefisien aktif dan CV RMSE 5.4385. Jadi, A3 lebih tepat dibaca sebagai studi trade-off: regularisasi tidak memenangkan akurasi absolut, tetapi Lasso dapat

membuat model lebih sparse dengan penurunan performa yang kecil.




Fig. 5: Sensitivitas A3 terhadap alpha, jenis regularisasi, dan sparsity. Regularisasi moderat dapat mengurangi koefisien aktif, sedangkan regularisasi berlebihan menyebabkan underfitting.

V. REKAPITULASI HASIL ANTAR-ABLASI

Setelah setiap kelompok dibahas secara terpisah, hasil terbaik dari masing-masing tahap dirangkum pada Tabel X. Pemilihan dilakukan menggunakan CV RMSE mean, sehingga test set tetap hanya berfungsi sebagai evaluasi akhir.

A1- $k = 7$ menjadi konfigurasi terbaik secara keseluruhan dengan CV RMSE 5.4140 ± 0.5716 . Nilai test juga paling baik di antara konfigurasi terbaik tiap keluarga: RMSE 5.0745, MAE 4.1139, dan $R^2 = 0.8996$. Perbedaannya terhadap B0 kecil, sehingga hasil ini lebih tepat dipahami sebagai efisiensi representasi yang hampir tidak mengorbankan performa daripada sebagai peningkatan akurasi yang besar.




Fig. 6: Perbandingan dimensi akhir dan CV RMSE serta hubungan CV RMSE dengan test RMSE pada seluruh konfigurasi.

VI. GAP TRAINING-VALIDATION-TESTING

Untuk melihat konsistensi performa, gap dihitung sebagai perbedaan (Δ) antara train RMSE dan test RMSE

TABLE IX: Hasil lengkap A3.

Metode	α	l_1	Nonzero	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
ElasticNet	0.0001	0.1	18	5.4815 ± 0.5892	5.1510	4.1923	0.8965
ElasticNet	0.0001	0.5	18	5.4815 ± 0.5892	5.1510	4.1923	0.8965
ElasticNet	0.0001	0.9	18	5.4815 ± 0.5893	5.1509	4.1923	0.8965
ElasticNet	0.0010	0.1	18	5.4807 ± 0.5885	5.1513	4.1920	0.8965
ElasticNet	0.0010	0.5	18	5.4806 ± 0.5885	5.1508	4.1917	0.8965
ElasticNet	0.0010	0.9	18	5.4806 ± 0.5885	5.1502	4.1914	0.8966
ElasticNet	0.0100	0.1	17	5.4754 ± 0.5813	5.1561	4.1928	0.8963
ElasticNet	0.0100	0.5	17	5.4732 ± 0.5812	5.1497	4.1881	0.8966
ElasticNet	0.0100	0.9	17	5.4715 ± 0.5811	5.1438	4.1841	0.8968
ElasticNet	0.1000	0.1	17	5.6136 ± 0.5361	5.3532	4.3364	0.8882
ElasticNet	0.1000	0.5	13	5.5060 ± 0.5392	5.2231	4.2472	0.8936
ElasticNet	0.1000	0.9	9	5.4385 ± 0.5477	5.1259	4.1663	0.8975
ElasticNet	1.0000	0.1	13	9.4968 ± 0.6039	9.0588	6.9279	0.6800
ElasticNet	1.0000	0.5	7	8.1523 ± 0.5791	7.8072	6.0346	0.7623
ElasticNet	1.0000	0.9	7	6.3921 ± 0.5378	6.1415	4.8851	0.8529
ElasticNet	10.0000	0.1	7	15.7417 ± 0.8605	14.8147	11.4011	0.1441
ElasticNet	10.0000	0.5	2	15.8104 ± 0.8783	14.8675	11.4511	0.1380
ElasticNet	10.0000	0.9	1	15.0297 ± 0.8687	14.1385	10.8929	0.2205
ElasticNet	100.0000	0.1	1	17.0421 ± 0.9153	16.0181	12.3524	-0.0006
ElasticNet	100.0000	0.5	0	17.0796 ± 0.9161	16.0532	12.3804	-0.0050
ElasticNet	100.0000	0.9	0	17.0796 ± 0.9161	16.0532	12.3804	-0.0050
Lasso	0.0001	—	18	5.4815 ± 0.5893	5.1509	4.1922	0.8965
Lasso	0.0010	—	18	5.4806 ± 0.5885	5.1501	4.1914	0.8966
Lasso	0.0100	—	17	5.4712 ± 0.5811	5.1424	4.1832	0.8969
Lasso	0.1000	—	9	5.4311 ± 0.5519	5.1096	4.1506	0.8982
Lasso	1.0000	—	7	6.0182 ± 0.5177	5.7683	4.6326	0.8702
Lasso	10.0000	—	1	13.8644 ± 0.8590	13.0541	10.0559	0.3355
Lasso	100.0000	—	0	17.0796 ± 0.9161	16.0532	12.3804	-0.0050
Ridge	0.0001	—	18	5.4816 ± 0.5893	5.1510	4.1923	0.8965
Ridge	0.0010	—	18	5.4816 ± 0.5893	5.1510	4.1923	0.8965
Ridge	0.0100	—	18	5.4816 ± 0.5893	5.1510	4.1923	0.8965
Ridge	0.1000	—	18	5.4814 ± 0.5892	5.1510	4.1923	0.8965
Ridge	1.0000	—	18	5.4803 ± 0.5881	5.1515	4.1920	0.8965
Ridge	10.0000	—	18	5.4758 ± 0.5784	5.1602	4.1963	0.8962
Ridge	100.0000	—	18	5.7969 ± 0.5257	5.4914	4.4390	0.8824

TABLE X: Rekap konfigurasi kontrol dan konfigurasi terbaik dari setiap kelompok ablasi.

Tahap	Konfigurasi	CV RMSE (mean $\pm$ SD)	Test RMSE	Test MAE	Test R^2
B0	B0	5.4221 ± 0.5827	5.0913	4.1302	0.8989
B1	B1_standard	5.4221 ± 0.5827	5.0913	4.1302	0.8989
B2	B2_standard	5.4816 ± 0.5893	5.1510	4.1923	0.8965
B3	B3_standard	5.4803 ± 0.5881	5.1515	4.1920	0.8965
A1 ($k = 7$)	A1_k7	5.4140 ± 0.5716	5.0745	4.1139	0.8996
A2 (80%)	A2_PCA_80	5.4359 ± 0.5984	5.0971	4.1184	0.8987
A3 (Lasso, $\alpha = 0.1$)	A3_Lasso_alpha_0.1	5.4311 ± 0.5519	5.1096	4.1506	0.8982

serta antara CV RMSE dan test RMSE. Nilai negatif berarti RMSE test lebih rendah daripada nilai pembanding. Tabel XI merangkum konfigurasi terbaik dari setiap tahap agar pola generalisasi dapat dibandingkan tanpa membuat tabel 49 baris terlalu padat.

Pada A1- $k = 7$, train RMSE sebesar 5.3767, CV RMSE 5.4140, dan test RMSE 5.0745. Δ CV/test gap sebesar -0.3395 menunjukkan bahwa pada split yang digunakan, hold-out test sedikit lebih mudah daripada rata-rata validation fold. Pola negatif yang serupa muncul pada sebagian besar konfigurasi. Karena test set tidak digunakan dalam pemilihan model, perbedaan ini tidak diperlakukan sebagai data leakage.

VII. PERBEDAAN TERHADAP BASELINE (Δ)

Pada bagian akhir, setiap konfigurasi terbaik dari tiap tahap dibandingkan langsung dengan B0. Untuk RMSE dan MAE, $\Delta < 0$ berarti galat menurun dibandingkan baseline. Untuk R^2 , $\Delta > 0$ berarti performa meningkat.

Dengan cara ini, arah perubahan dapat dibaca lebih cepat daripada hanya membandingkan nilai absolut.

Tabel XII memperlihatkan bahwa B1 memiliki $\Delta = 0$ pada seluruh metrik karena scaling tidak mengubah prediksi OLS. B2 dan B3 memberikan perubahan negatif pada R^2 dan positif pada RMSE, sehingga keduanya sedikit lebih buruk daripada baseline. A1- $k = 7$ merupakan satu-satunya konfigurasi terbaik keluarga yang memberikan perbaikan serentak pada test RMSE, test MAE, dan test R^2 : masing-masing -0.0168 , -0.0163 , dan $+0.0007$. A2 dan A3 tidak mengungguli baseline pada seluruh metrik sekaligus, tetapi tetap memberikan alternatif kompresi atau sparsity yang relevan.

VIII. ANALISIS RESIDUAL MODEL TERPILIH

Konfigurasi akhir dipilih menggunakan mean CV RMSE terendah, yaitu A1- $k = 7$. Pada hold-out test, model memperoleh RMSE 5.0745, MAE 4.1139, dan $R^2 = 0.8996$. Rata-rata residual adalah -0.0403 dengan simpangan baku 5.0871. Nilai rata-rata residual yang dekat dengan nol


TABLE XI: Gap performa training, cross-validation, dan hold-out testing.

Tahap	Train RMSE	CV RMSE	Test RMSE	Δ Train/Test	Δ CV/Test	Train R^2	Test R^2
B0	5.3754	5.4221	5.0913	-0.2841	-0.3308	0.9010	0.8989
B1	5.3754	5.4221	5.0913	-0.2841	-0.3308	0.9010	0.8989
B2	5.3447	5.4816	5.1510	-0.1938	-0.3306	0.9021	0.8965
B3	5.3448	5.4803	5.1515	-0.1933	-0.3288	0.9021	0.8965
A1 ($k = 7$)	5.3767	5.4140	5.0745	-0.3022	-0.3395	0.9009	0.8996
A2 (80%)	5.3880	5.4359	5.0971	-0.2910	-0.3388	0.9005	0.8987
A3 (Lasso, $\alpha = 0.1$)	5.3725	5.4311	5.1096	-0.2630	-0.3216	0.9011	0.8982

TABLE XII: Perbedaan metrik konfigurasi terbaik tiap tahap terhadap B0.

Tahap	Δ CV RMSE	Δ CV MAE	Δ CV R^2	Δ Test RMSE	Δ Test MAE	Δ Test R^2
B0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
B1	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
B2	0.0595	0.0462	-0.0023	0.0597	0.0621	-0.0024
B3	0.0582	0.0455	-0.0023	0.0602	0.0618	-0.0024
A1 ($k = 7$)	-0.0081	-0.0064	0.0004	-0.0168	-0.0163	0.0007
A2 (80%)	0.0138	0.0211	-0.0005	0.0058	-0.0118	-0.0002
A3 (Lasso, $\alpha = 0.1$)	0.0090	0.0178	-0.0002	0.0183	0.0204	-0.0007

menunjukkan tidak ada bias rata-rata yang besar pada split test ini. Grafik actual-versus-predicted dan residual digunakan sebagai diagnosis tambahan, bukan sebagai dasar pemilihan model.

Fig. 7: Diagnostik residual A1- $k = 7$: actual versus predicted, distribusi residual, dan residual terhadap prediksi.

IX. PEMBAHASAN

Urutan hasil menunjukkan bahwa tidak semua perubahan pada pipeline memberikan kontribusi yang sama. B1 bersifat netral terhadap OLS, B2 menambah dimensi tetapi sedikit menurunkan performa, dan B3 dengan Ridge $\alpha = 1$ belum memberikan keuntungan yang berarti. Tidak adanya gap training-test yang mengarah pada overfitting pada B0 juga menjelaskan mengapa Ridge, Lasso, dan ElasticNet tidak memberikan peningkatan akurasi yang berarti: regularisasi tidak memiliki kompleksitas berlebih yang jelas untuk dikendalikan. Perubahan yang paling informatif justru muncul ketika dimensi 18 fitur dikurangi secara terkontrol melalui A1 dan A2, atau ketika koefisien dibuat sparse melalui A3.

A1 memberikan hasil paling menarik karena perubahan performanya kecil tetapi struktur model menjadi jauh lebih sederhana. Dari 18 fitur hasil encoding, tujuh fitur sudah cukup untuk menghasilkan CV RMSE terbaik. Secara statistik, seleksi tersebut kemungkinan mempertahankan fitur dengan hubungan marginal paling kuat terhadap target dan membuang fitur yang sinyalnya lebih lemah atau informasinya relatif tumpang tindih. Sebaliknya, $k = 4$ terlalu agresif dan menyebabkan penurunan performa yang

jelas. Hal ini menunjukkan adanya titik kompromi antara pengurangan dimensi dan kehilangan informasi.

PCA juga berhasil melakukan kompresi, tetapi komponen PCA tidak mempunyai interpretasi langsung seperti fitur asli, karena setiap komponen merupakan kombinasi linear dari variabel awal [3]. Pada tugas ini, A1 lebih menguntungkan karena sekaligus mempertahankan interpretabilitas variabel dan menghasilkan performa sedikit lebih baik. A3 memberikan bentuk sparsity yang berbeda: Lasso $\alpha = 0.1$ mengurangi koefisien aktif menjadi sembilan, sehingga berguna apabila tujuan praktisnya adalah model yang lebih ringkas.

Secara keseluruhan, nilai perubahan terhadap baseline relatif kecil. Karena itu, klaim yang paling tepat bukan bahwa satu teknik “sangat meningkatkan” akurasi, melainkan bahwa studi ablasi berhasil menunjukkan komponen mana yang netral, mana yang menambah kompleksitas tanpa keuntungan, dan mana yang dapat menyederhanakan model dengan tetap mempertahankan performa.

X. KETERBATASAN

Kesimpulan berlaku pada dataset dan rancangan eksperimen yang digunakan. Hanya satu fixed 80:20 train-test split yang digunakan, sehingga skor test bukan estimasi berulang dari generalisasi eksternal. Sepuluh-fold cross-validation memberikan dasar yang lebih kuat untuk membandingkan konfigurasi, tetapi simpangan baku fold bukan confidence interval.

Keluarga model dibatasi pada regresi linear dan variannya. Model non-linear berada di luar cakupan studi ini. Selain itu, laporan tidak membuat klaim mengenai representativitas populasi atau proses pengumpulan dataset di luar informasi yang tersedia dalam data dan hasil eksperimen.

XI. KESIMPULAN

Studi ablasi ini memperlihatkan bahwa perubahan paling berguna pada pipeline bukan selalu preprocessing yang paling umum digunakan. Standardisasi tidak mengubah

prediksi OLS, penambahan fitur kategorikal sedikit menurunkan performa, PCA memberikan kompresi dengan performa yang masih dekat dengan baseline, sedangkan Ridge, Lasso, dan ElasticNet tidak memberikan peningkatan akurasi yang berarti karena baseline sejak awal tidak menunjukkan indikasi overfitting yang kuat. Nilai tambah regularisasi pada eksperimen ini terutama terletak pada sparsity dan pengurangan kompleksitas koefisien.

Konfigurasi terbaik berdasarkan mean CV RMSE adalah $A1-k = 7$, dengan CV RMSE 5.4140 ± 0.5716 . Pada hold-out test, konfigurasi tersebut memperoleh RMSE 5.0745, MAE 4.1139, dan $R^2 = 0.8996$, sambil mengurangi representasi dari 18 menjadi tujuh fitur. Nilai perubahan terhadap baseline memang kecil, tetapi justru menunjukkan bahwa keuntungan utama dari ablasi ini adalah memperoleh model yang lebih ringkas tanpa kehilangan performa prediksi.

REFERENCES

- [1] R. Kohavi, "A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection," in *Proc. 14th Int. Joint Conf. Artificial Intelligence (IJCAI)*, 1995, pp. 1137–1145.
- [2] I. Guyon and A. Elisseeff, "An Introduction to Variable and Feature Selection," *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003.
- [3] I. T. Jolliffe and J. Cadima, "Principal component analysis: a review and recent developments," *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065, Art. no. 20150202, 2016, doi: 10.1098/rsta.2015.0202.
- [4] A. E. Hoerl and R. W. Kennard, "Ridge Regression: Biased Estimation for Nonorthogonal Problems," *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970, doi: 10.1080/00401706.1970.10488634.
- [5] R. Tibshirani, "Regression Shrinkage and Selection Via the Lasso," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 58, no. 1, pp. 267–288, 1996, doi: 10.1111/j.2517-6161.1996.tb02080.x.
- [6] H. Zou and T. Hastie, "Regularization and Variable Selection Via the Elastic Net," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 67, no. 2, pp. 301–320, 2005, doi: 10.1111/j.1467-9868.2005.00503.x.

REPRODUCIBILITY

Kode eksperimen dan hasil dapat diakses melalui Google Colab dan repositori GitHub.